Sujet 5 — Arbitrage statistique par facteurs de risque (PCA)

Principe général

L'idée de ce sujet est de décomposer le rendement de chaque actif i en une partie expliquée par des facteurs de risque communs à l'ensemble du marché, et un résidu propre à l'actif :

$$r_{i,t} = \beta_i^\top F_t + \varepsilon_{i,t}, \tag{1}$$

où F_t est un vecteur de facteurs de risque communs (non observés directement, mais estimés statistiquement). La stratégie consiste à isoler la partie résiduelle $\varepsilon_{i,t}$ – censée ne plus contenir de risque de marché commun – et à parier sur son caractère *mean-reverting* (retour à la moyenne) une fois cumulée dans le temps.

Étape 1 : estimer les facteurs F_t par PCA

On estime la matrice de corrélation empirique $\hat{\Sigma}$ des rendements des N actifs de l'univers considéré, et on en extrait les k premiers vecteurs propres (ceux associés aux plus grandes valeurs propres) : ils définissent des *portefeuilles propres* (eigenportfolios), combinaisons linéaires des rendements des actifs, qui jouent le rôle de facteurs de marché implicites F_t.

Attention au bruit d'estimation. Lorsque le nombre d'actifs N et le nombre d'observations T sont du même ordre de grandeur (c'est-à-dire que N/T n'est pas négligeable), la matrice de corrélation empirique $\hat{\Sigma}$ est fortement bruitée : une part significative de son spectre de valeurs propres ne reflète que du bruit d'échantillonnage et non une réelle structure de corrélation. La théorie de Marchenko-Pastur donne la loi limite du spectre d'une matrice de corrélation purement aléatoire (sans structure), ce qui permet de déterminer un seuil au-delà duquel une valeur propre peut être considérée comme statistiquement significative plutôt que due au bruit. Il faut donc *débruiter* $\hat{\Sigma}$ avant d'en extraire les facteurs, par exemple via le shrinkage de Ledoit-Wolf (qui régularise la matrice vers une cible structurée), ou via les méthodes de nettoyage spectral de Bouchaud-Potters (qui consistent typiquement à conserver telles quelles les valeurs propres significatives au sens de Marchenko-Pastur, et à remplacer les autres par une valeur constante reflétant le bruit résiduel). Ne garder que les k composantes significatives permet aussi d'éviter que les résidus $\varepsilon_{i,t}$ ne soient en réalité en partie du signal de facteur mal filtré (overfitting).

Étape 2 : régression rolling et résidus

Pour chaque actif i, on régresse ses rendements sur les k facteurs obtenus par PCA, de façon glissante dans le temps (rolling), pour obtenir une estimation de β_i à chaque instant. Deux approches sont possibles :

— **OLS glissant** : on estime β_i par moindres carrés sur une fenêtre glissante de longueur fixe. Le β_i obtenu est constant sur la fenêtre, ce qui peut mal capter une exposition au marché qui évolue en continu.

— **Filtre de Kalman** : on modélise β_i comme un état latent évoluant dans le temps (par exemple une marche aléatoire), mis à jour à chaque nouvelle observation. Cette approche est plus réaliste (le β_i peut varier en continu plutôt que par sauts liés à la fenêtre glissante) et évite naturellement le biais de *look-ahead* inhérent à une fenêtre glissante centrée ou mal calée, puisque la mise à jour à l'instant t n'utilise que l'information disponible jusqu'à t.

Étape 3 : dynamique des résidus cumulés et signal

On définit le résidu cumulé $X_{i,t} = \sum_{s \leq t} \varepsilon_{i,s}$, que l'on modélise comme un processus d'Ornstein-Uhlenbeck : $dX_t = \kappa(m - X_t)dt + \sigma\, dW_t$. En discrétisant, on obtient un modèle AR(1) : $X_{n+1} = a + bX_n + \zeta_n$, dont l'estimation (par exemple par OLS) donne $\kappa = -\ln(b)/\Delta t$ et $m = a/(1-b)$. On ne retient pour le trading que les actifs dont la demi-vie $\ln(2)/\kappa$ est suffisamment courte, afin de s'assurer que le retour à la moyenne se produit sur un horizon compatible avec la stratégie.

Le signal de trading, le *s-score*, est alors défini par

$$s_i = \frac{X_{i,t} - m_i}{\sigma_{eq,i}}, \qquad \sigma_{eq,i} = \sqrt{\frac{\sigma_i^2}{2\kappa_i}}, \tag{2}$$

où $\sigma_{eq,i}$ est l'écart-type stationnaire du processus d'Ornstein-Uhlenbeck. Si s_i est très positif, l'actif i est jugé « trop monté » par rapport à sa valeur d'équilibre statistique : on le short, en pariant sur son retour à la moyenne. Si s_i est très négatif, on le long.

Quid de la couverture du terme en F_t ?

C'est indispensable pour que la stratégie soit effectivement une stratégie d'arbitrage *statistique* neutre au marché, et non un simple pari directionnel déguisé. En pratique, prendre position uniquement sur l'actif i (long ou short selon le signe de s_i) laisserait le portefeuille exposé à l'ensemble des facteurs de risque communs F_t, alors que le signal s_i ne porte que sur la partie résiduelle $\varepsilon_{i,t}$. Pour neutraliser cette exposition, il faut construire les portefeuilles propres identifiés par la PCA comme des instruments réellement tradés : chaque eigenportfolio k est une combinaison linéaire des N actifs de l'univers, avec des poids donnés par les composantes du k-ième vecteur propre (généralement pondérées par l'inverse de la volatilité de chaque actif). Pour chaque unité de l'actif i détenue, on prend alors une position opposée de $\beta_{i,k}$ unités dans chacun de ces k portefeuilles propres. Le portefeuille global (actif i moins ses expositions aux k portefeuilles propres) est alors, par construction, neutre aux facteurs de risque communs, et son P&L ne dépend plus que de la dynamique du résidu $\varepsilon_{i,t}$ sur lequel porte réellement le signal.

Remarque générale

Ce qui précède est une trame indicative. La littérature sur ce sujet (Avellaneda & Lee notamment) est riche, et il est attendu que l'équipe approfondisse chaque étape (choix du nombre de facteurs, méthode de débruitage, seuils d'entrée/sortie sur le s-score, gestion du risque de queue) bien au-delà de ce qui est présenté ici.